

Adaptive Architecture for Pentest Agents

Manager, Observer, Solver

绿盟科技 AI 小分队



About me

第二届智能渗透挑战赛·决赛
铸刃止戈 以智御危

AI 小分队

我们来自绿盟科技运营服务BG高级攻防部，深耕实战攻防，代码驱动决策，重构实战效能。

代码为剑，Agent 为魂，重构智能攻防边界。



NSFOCUS


目录


CONTENTS

PART 01 *Architecture*

PART 02 *Harness*

PART 03 *Summary*






PART 01

Architecture





- **智能决策要有工程边界：**让 LLM 负责规划、判断和调度，但所有动作都必须通过受控工具、资源上限和生命周期约束落地。
- **执行环境必须隔离可重置：**渗透测试 Agent 会运行脚本、安装工具、接触恶意服务，必须用容器隔离执行，避免污染宿主环境。
- **经验要沉淀成共享状态：**不要让每个 Agent 从零开始，把失败边界、成功经验沉淀下来，形成可继承的团队经验。
- **架构要做“稳定骨架”，不要做“能力枷锁”：**Agent 的核心能力来自模型本身，系统架构只应提供必要的状态、工具、隔离和反馈闭环；不要用过度复杂的流程、越精简、稳定、可组合的框架，越能随着模型能力提升而自然进化。

Agent Architecture: Overview

第二届智能渗透挑战赛·决赛

铸刃止戈 以智御危



- 控制面与执行面解耦，支撑 Agent 自主推进
- 容器化隔离执行，兼顾工程落地与本机安全
- 统一状态回传与协作通道，形成持续反馈闭环
- 根据反馈快速调整策略，提升解题效率

Agent Architecture: Overview

第二届智能渗透挑战赛·决赛
铸刃止戈 以智御危

- 策略可配置：调度、模型、Prompt、工具均可动态调整
- Agent 可自由组合：LLM + Prompt + Tools + Skills + Observer
- 过程可追踪：Solver 日志、Memory、Idea、提交记录全量留痕
- 结果可复盘：从拿到 Flag 回溯到路线、成本与关键决策



Challenge Stats

图表化展示题目完成情况，以及模型 / Prompt 维度统计。

Overview Models Prompts

Model Performance · Summary

Items

8

Avg Flag Rate

14%

Avg Time


1391 min

Avg Tokens

337151k

Success Time Tokens Quality


Model Performance · Flags



Agent Architecture: Manager Agent Design

第二届智能建造挑战赛·决赛

铸刃止戈 以智御危




- 从全局上下文中感知战场状态，而非静态排队调度
- 用 LLM 做规划与路线选择，用工程约束控制执行边界
- 通过受控工具把策略转化为可执行调度动作
- 在资源、安全和效率之间动态平衡

面向阶梯式解锁的阶段化调度：前期优先突破关键赛区，简单题并行清扫，后期对难题持续轮换模型与路线。

Agent Architecture: Solver Agent Collaboration

第二届智能渗透挑战赛·决赛
铸刃止戈 以智御危



- **并行探索:** 多个 Solver 独立尝试不同攻击路线
- **局部沉淀:** Observer 提炼失败边界、有效线索与候选思路
- **全局继承:** Hint、Flag 路线、Idea、Memory 进入共享状态
- **消息广播:** 提升 Solver Team 协作效率, 增强有效信息熵

• 每一次探索都不应消失, 而应沉淀为下一次突破的起点。

PART 02

Harness



Observer Harness: Efficiency Reminder

第二届智能渗透挑战赛·决赛

铸刃止戈 以智御危



痛点: Agent长任务中容易被近期上下文和工具反馈牵引, 执行策略会逐步发生偏移

引入 Observer Agent, 基于任务目标持续审查最近几轮执行表现和工具调用反馈, 不干预 Agent 推进任务,而是判断当前推进是否仍然有效, 在适当的时机做打断

Observer Harness: Memory & Idea

第二届智能渗透挑战赛·决赛

铸刃止戈 以智御危




长任务推进到后期, 真正先失真的往往不是能力, 而是状态本身: 假设、证据、失败边界和过程日志逐渐混在一起

将状态拆成两层: Idea 维护当前值得推进的攻击方向, Memory 保留可跨轮复用的事实、证据与约束
Observer 持续整理、更新和压缩这两块状态板, 让 Solver 始终面向低噪音、可决策的上下文推进任务

Observer Harness: Ralph-Loop

第二届智能渗透挑战赛·决赛

铸刃止戈 以智御危



长任务执行中, Agent 可能因误判、停顿或上下文退化而过早结束任务

我们将“任务是否结束”的判断从模型主观决策中抽离, 改由系统基于任务状态统一约束

结束条件由任务状态决定, 而不是由模型当下的主观判断决定。

Context Harness: Compaction

第二届智能渗透挑战赛·决赛


铸刃止戈 以智御危



RTK 负责输出 AI-friendly 的命令结果, 超长工具结果落地到文件, 避免直接污染上下文



长任务中的上下文压力, 主要来自大量原始工具输出和历史会话堆积, 造成上下文腐败导致模型降智



PART 03

Summary




Cost

第二届智能渗透挑战赛·决赛

铸刃止戈 以智御危



$Total\ Cost = \$2757.6251 * 2.5 + 491.79¥(kimi) \approx 7,385.85275\ ¥$



Model Performance

第二届智能语言挑战赛·决赛
铸刃止戈 以智御危

Name	Challenges	Flags	Flag Rate	Error	Time	Tokens	Quality
claude-opus-4-6	37	42/53	79%	35%	6713 min	1761170k	35500
glm-5.1	5	2/10	20%	0%	2086 min	386836k	3000
kimi-k2.5	27	3/27	11%	81%	970 min	156220k	2200
gpt-5.4	3	0/8	0%	100%	720 min	216099k	0
gpt-5.3-codex	2	0/7	0%	0%	374 min	100678k	0
glm-5-turbo	1	0/6	0%	0%	193 min	74963k	0
gemini-3-pro-preview	1	0/6	0%	0%	63 min	154k	0



多模型并行探索，提升覆盖面与成功概率

在我们这套工程架构下，国产模型仍具备一定的竞争力。

THANKS

